

MGE-201: Intervalos y regiones de confianza

Felipe Osorio

felipe.osorio@uv.cl

El objetivo de esta sección es abordar el problema $\theta \in C$, donde $C \subseteq \Theta$, $C = C(\mathbf{X})$ es un conjunto determinado por los datos observados $\mathbf{X} = \mathbf{x}$.¹

Definición 1:

Una estimación intervalar de un parámetro real-valuado θ es cualquier par de funciones $L(x_1, \dots, x_n)$ y $U(x_1, \dots, x_n)$ que satisfacen

$$L(\mathbf{x}) \leq U(\mathbf{x}), \quad \forall \mathbf{x} \in \mathcal{X}.$$

Para $\mathbf{X} = \mathbf{x}$ tenemos $L(\mathbf{x}) \leq \theta \leq U(\mathbf{x})$, mientras que $[L(\mathbf{X}), U(\mathbf{X})]$ es un intervalo aleatorio.

¹Si θ es real-valuado, entonces C corresponde a un intervalo.

Intervalos de confianza

Ejemplo:

Considere X_1, X_2, X_3, X_4 una muestra aleatoria desde $N(\mu, 1)$. Un estimador intervalar de μ es $[\bar{X} - 1, \bar{X} + 1]$, es decir

$$\mu \in [\bar{X} - 1, \bar{X} + 1]$$

Note que $\bar{X} \sim N(\mu, 1/4)$, pero

$$P(\bar{X} = \mu) = 0.$$

Mientras que,

$$\begin{aligned} P(\mu \in [\bar{X} - 1, \bar{X} + 1]) &= P(\bar{X} - 1 \leq \mu \leq \bar{X} + 1) = P(-1 \leq \mu - \bar{X} \leq 1) \\ &= P(-1 \leq \bar{X} - \mu \leq 1) = P\left(-\frac{1}{\sqrt{1/4}} \leq \frac{\bar{X} - \mu}{\sqrt{1/4}} \leq \frac{1}{\sqrt{1/4}}\right) \\ &= P\left(-2 \leq \frac{\bar{X} - \mu}{\sqrt{1/4}} \leq 2\right) = P(-2 \leq Z \leq 2) = 0.9544 \end{aligned}$$

pues $Z = (\bar{X} - \mu)/\sqrt{1/4} \sim N(0, 1)$.

Interpretación:

Tenemos un 95% de chances de cubrir el parámetro verdadero (desconocido) con nuestro estimador intervalar.

Observación:

En este contexto $P_{\theta}(\theta \in [L(\mathbf{x}), U(\mathbf{x})])$ se denomina **probabilidad de cobertura**

Definición 2:

El **coeficiente de confianza** de $[L(\mathbf{x}), U(\mathbf{x})]$ es el ínfimo de las probabilidades de cobertura

$$\inf_{\theta} P_{\theta}(\theta \in [L(\mathbf{x}), U(\mathbf{x})])$$

Observación:

Estimadores intervalares en conjunto con una medida de confianza (coeficiente de confianza) son conocidos como **intervalos de confianza**.

Definición 3:

Una variable aleatoria $Q(\mathbf{X}; \theta) = Q(X_1, \dots, X_n; \theta)$ es una **cantidad pivotal** (pivote) si la distribución de $Q(\mathbf{X}; \theta)$ **no** depende de θ . Esto es, si

$$\mathbf{X} \sim F(\mathbf{x}; \theta) \quad \Rightarrow \quad Q(\mathbf{X}; \theta),$$

tiene la misma distribución para todo valor de θ .

Observación:

La técnica confía en la habilidad de hallar un pivote y un conjunto A tal que el conjunto $\{\theta : Q(\mathbf{X}; \theta) \in A\}$ sea una estimación intervalar para θ .

Intervalos de confianza

Ejemplo:

Si X_1, \dots, X_n es una muestra aleatoria de tamaño n desde $N(\mu, \sigma^2)$, entonces

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1),$$

y por tanto es un pivote para μ (siempre que σ^2 sea conocido). Para cualquier constante a sigue que:

$$\begin{aligned} P\left(-a \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq a\right) &= P\left(-a \frac{\sigma}{\sqrt{n}} \leq \bar{X} - \mu \leq a \frac{\sigma}{\sqrt{n}}\right) \\ &= P\left(\bar{X} - a \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + a \frac{\sigma}{\sqrt{n}}\right), \end{aligned}$$

es decir obtenemos el intervalo de confianza

$$\left[\bar{X} - a \frac{\sigma}{\sqrt{n}}; \bar{X} + a \frac{\sigma}{\sqrt{n}}\right].$$

Intervalos de confianza

Podemos escribir también,

$$\left\{ \mu : \bar{X} - a \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + a \frac{\sigma}{\sqrt{n}} \right\}.$$

Además suponga que $a = z_{1-\alpha/2}$ para un valor de α dado. Entonces, es fácil notar que

$$P \left(\mu \in \left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right] \right) = 1 - \alpha,$$

corresponde a un intervalo de confianza del $100(1 - \alpha)\%$ para μ .

Observación:

Note que este intervalo de confianza es [simétrico](#).

Intervalos de confianza

Ejemplo:

Si X_1, \dots, X_n es una muestra aleatoria de tamaño n desde $N(\mu, \sigma^2)$ con σ^2 desconocido. Para este caso, podemos usar el pivote

$$T = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1),$$

es decir,

$$P(-a \leq T \leq a) = P\left(-a \leq \frac{\bar{X} - \mu}{s/\sqrt{n}} \leq a\right)$$

que lleva al intervalo de confianza

$$\left\{ \mu : \bar{X} - t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{1-\alpha/2}(n-1) \frac{s}{\sqrt{n}} \right\}.$$

Intervalos de confianza

Ejemplo:

Considere ahora,

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$

que es cantidad pivotal y elija a y b , satisfaciendo que

$$P(a \leq \chi^2 \leq b) = P\left(a \leq \frac{(n-1)S^2}{\sigma^2} \leq b\right) = 1 - \alpha,$$

desde donde obtenemos

$$\left\{ \sigma^2 : \frac{(n-1)S^2}{b} \leq \sigma^2 \leq \frac{(n-1)S^2}{a} \right\}.$$

Las elecciones de a y b que producen el intervalo con el coeficiente de confianza requerido son $a = \chi_{1-\alpha/2}^2(n-1)$ y $b = \chi_{\alpha/2}^2(n-1)$.

Definición 4 (Intervalo de confianza asintótico):

Considere $SE = \sqrt{\text{var}(\hat{\theta}_n)}$. Entonces $\widehat{SE} = \sqrt{1/\mathcal{F}_n(\hat{\theta}_n)}$, luego un **intervalo de confianza asintótico** del $100(1 - \alpha)\%$ para θ es dado por:²

$$IC_n(\theta) = [\hat{\theta}_n - z_{1-\alpha/2}\widehat{SE}, \hat{\theta}_n + z_{1-\alpha/2}\widehat{SE}].$$

Este procedimiento está basado en la “**cantidad pivotal**”

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N_1(0, \mathcal{F}_1^{-1}(\theta)),$$

es decir,

$$\frac{\hat{\theta}_n - \theta}{\sqrt{\text{var}(\hat{\theta}_n)}} \xrightarrow{D} N_1(0, 1).$$

²En efecto, $P_\theta(\theta \in IC_n(\theta)) \rightarrow 1 - \alpha$ para $n \rightarrow \infty$.

Intervalos de confianza

Ejemplo:

Sea X_1, \dots, X_n muestra aleatoria desde $\text{Ber}(p)$. Sabemos que el MLE de p es $\hat{p}_n = \frac{1}{n} \sum_{i=1}^n x_i$, y

$$\log f(x; p) = x \log p + (1 - x) \log(1 - p),$$

así

$$U(x; p) = \frac{x}{p} - \frac{1 - x}{1 - p}, \quad U'(x; p) = \frac{x}{p^2} + \frac{1 - x}{(1 - p)^2}.$$

De este modo,

$$\mathcal{F}_1(p) = \mathbb{E}\{-U'(X; p)\} = \frac{p}{p^2} + \frac{1 - p}{(1 - p)^2} = \frac{1}{p} + \frac{1}{1 - p} = \frac{1}{p(1 - p)},$$

de ahí que

$$\widehat{\text{SE}} = \frac{1}{\sqrt{\mathcal{F}_n(\hat{p}_n)}} = \frac{1}{\sqrt{n\mathcal{F}_1(\hat{p}_n)}} = \sqrt{\frac{\hat{p}_n(1 - \hat{p}_n)}{n}},$$

luego, un intervalo de confianza del $100(1 - \alpha)\%$ para p es dado por

$$\hat{p}_n \mp z_{1-\alpha/2} \sqrt{\frac{\hat{p}_n(1 - \hat{p}_n)}{n}}.$$

Observación:

Considere $\lambda = g(\theta)$. Sabemos que el estimador ML de λ es dado por $\hat{\lambda}_n = g(\hat{\theta}_n)$. Además, usando el método Delta, sigue que

$$\frac{\hat{\lambda}_n - \lambda}{\widehat{SE}(\hat{\lambda}_n)} \xrightarrow{D} N(0, 1),$$

donde

$$\widehat{SE}(\hat{\lambda}_n) = |g'(\hat{\theta}_n)| \widehat{SE}(\hat{\theta}_n).$$

Lo que lleva al intervalo de confianza asintótico

$$IC_n(\lambda) = [\hat{\lambda}_n - z_{1-\alpha/2} \widehat{SE}(\hat{\lambda}_n), \hat{\lambda}_n + z_{1-\alpha/2} \widehat{SE}(\hat{\lambda}_n)].$$

Ejemplo:

Considere X_1, \dots, X_n variables aleatorias IID desde una FE 1-paramétrica, y sea $\phi = \eta(\theta)$, $\gamma(\phi) = b(\theta)$. De este modo,

$$f(x; \phi) = \exp[\phi T(x) - \gamma(\phi)]h(x),$$

es decir, la log-verosimilitud para una única observación es dada por

$$\log f(x; \phi) = \phi T(x) - \gamma(\phi) + \log h(x).$$

Lo que lleva a,

$$U(x; \phi) = T(x) - \gamma'(\phi), \quad U'(x; \phi) = -\gamma''(\phi),$$

de ahí que, la información de Fisher es dada por

$$\mathcal{F}_1(\phi) = \mathbb{E}\{-U'(X; \phi)\} = \gamma''(\phi) = \text{var}(T(X)).$$

Intervalos de confianza

Es decir, el error estándar adopta la forma

$$\widehat{\text{SE}} = \frac{1}{\sqrt{\mathcal{F}_n(\hat{\phi}_n)}} = \frac{1}{\sqrt{n\mathcal{F}_1(\hat{\phi}_n)}} = \frac{1}{\sqrt{n\gamma''(\hat{\phi}_n)}},$$

donde $\hat{\phi}_n$ denota el MLE de ϕ . Finalmente, un intervalo de confianza del $100(1 - \alpha)\%$ para ϕ es dado por

$$IC_n(\phi) = \left[\hat{\phi}_n \mp z_{1-\alpha/2} \frac{1}{\sqrt{n\gamma''(\hat{\phi}_n)}} \right].$$

Evidentemente, también podemos considerar un intervalo de confianza asintótico para $\theta = g(\phi) = \eta^{-1}(\phi)$ usando el método Delta.

Resultado 1:

Sea $\{\mathbf{T}_n\}$ una secuencia de vectores aleatorios k -dimensionales tal que

$$\sqrt{n}(\mathbf{T}_n - \boldsymbol{\theta}) \xrightarrow{D} N_k(\mathbf{0}, \boldsymbol{\Sigma}),$$

y sea $\{\mathbf{A}_n\}$ una secuencia de matrices aleatorias tal que $\mathbf{A}_n \xrightarrow{P} \mathbf{A}$, donde $\mathbf{A}\boldsymbol{\Sigma}\mathbf{A} = \mathbf{A}$.
Entonces

$$Q_n = n(\mathbf{T}_n - \boldsymbol{\theta})^\top \mathbf{A}_n (\mathbf{T}_n - \boldsymbol{\theta}) \xrightarrow{D} \chi^2(k).$$

Demostración:

Ver detalles en Sen y Singer (1993), página 137.

Basado en la normalidad asintótica de los MLEs

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N_k(\mathbf{0}, \mathcal{F}_1^{-1}(\theta)),$$

y notando que $\mathcal{F}_1(\hat{\theta}_n) \xrightarrow{P} \mathcal{F}_1(\theta)$, tenemos

$$n(\hat{\theta}_n - \theta)^\top \mathcal{F}_1(\hat{\theta}_n)(\hat{\theta}_n - \theta) \xrightarrow{D} \chi^2(k).$$

Es decir, podemos construir una **región de confianza** del $100(1 - \alpha)\%$ para θ como:

$$RC_n(\theta) = \{\theta : n(\hat{\theta}_n - \theta)^\top \mathcal{F}_1(\hat{\theta}_n)(\hat{\theta}_n - \theta) \leq \chi_{1-\alpha}^2(k)\},$$

donde $\chi_{1-\alpha}^2(k)$ denota un valor cuantil $1 - \alpha$ de la distribución chi-cuadrado con k grados de libertad.

Ejemplo:

Considere X_1, \dots, X_n una muestra aleatoria desde $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Es fácil notar que

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} N_p(\mathbf{0}, \boldsymbol{\Sigma}),$$

y

$$\mathbf{S}_n = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}}_n)(\mathbf{X}_i - \bar{\mathbf{X}}_n)^\top \xrightarrow{P} \boldsymbol{\Sigma}.$$

De este modo, la estadística T^2 de Hotelling, satisface que

$$T_n^2 = n(\bar{\mathbf{X}}_n - \boldsymbol{\mu})^\top \mathbf{S}_n^{-1}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{D} \chi^2(p).$$

Luego, una región de confianza asintótica del $100(1 - \alpha)\%$ para $\boldsymbol{\mu}$ es dada por:

$$RC_n(\boldsymbol{\mu}) = \{\boldsymbol{\mu} : n(\bar{\mathbf{X}}_n - \boldsymbol{\mu})^\top \mathbf{S}_n^{-1}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \leq \chi_{1-\alpha}^2(p)\}.$$

Considere la siguiente expansión de Taylor,

$$\ell_n(\boldsymbol{\theta}) \stackrel{a}{=} \ell_n(\hat{\boldsymbol{\theta}}_n) + \left(\frac{\partial \ell_n(\hat{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta}} \right)^\top (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_n) + \frac{1}{2} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_n)^\top \frac{\partial^2 \ell_n(\hat{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_n).$$

Usando la condición de primer orden, sigue que

$$\ell_n(\hat{\boldsymbol{\theta}}_n) - \ell_n(\boldsymbol{\theta}) \stackrel{a}{=} \frac{1}{2} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_n)^\top \left\{ - \frac{\partial^2 \ell_n(\hat{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}} \right\} (\boldsymbol{\theta} - \hat{\boldsymbol{\theta}}_n).$$

Asumiendo independencia, tenemos que

$$\begin{aligned} \frac{1}{n} \left\{ - \frac{\partial^2 \ell_n(\hat{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}} \right\} &= \frac{1}{n} \sum_{i=1}^n - \frac{\partial^2 \ell_i(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} \\ &\xrightarrow{P} E \left\{ - \frac{\partial^2 \ell_1(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} \right\} = \mathcal{F}_1(\boldsymbol{\theta}) \end{aligned}$$

Por los razonamientos anteriores,

$$\ell_n(\widehat{\boldsymbol{\theta}}_n) - \ell_n(\boldsymbol{\theta}) \stackrel{a}{=} \frac{n}{2}(\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}}_n)^\top \mathcal{F}_1(\boldsymbol{\theta})(\boldsymbol{\theta} - \widehat{\boldsymbol{\theta}}_n),$$

es decir,

$$2\{\ell_n(\widehat{\boldsymbol{\theta}}_n) - \ell_n(\boldsymbol{\theta})\} \xrightarrow{D} \chi^2(k),$$

lo que lleva a la región de confianza asintótica:

$$RC_n^*(\boldsymbol{\theta}) = \{\boldsymbol{\theta} : 2(\ell_n(\widehat{\boldsymbol{\theta}}_n) - \ell_n(\boldsymbol{\theta})) \leq \chi_{1-\alpha}^2(k)\}.$$

En el contexto de **extremum estimators**, este decir $\hat{\theta}_n$ obtenido como solución del problema $\max_{\theta} Q_n(\theta)$,

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N_k(\mathbf{0}, A^{-1}BA^{-1}).$$

De este modo, obtenemos la región de confianza

$$RC_n^*(\theta) = \{\theta : n(\hat{\theta}_n - \theta)^\top AB^{-1}A(\hat{\theta}_n - \theta) \leq \chi_{1-\alpha}^2(k)\}.$$

Mientras que para **funciones de inferencia** del tipo $g(\theta) = \mathbf{0}$, sabemos que

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N_k(\mathbf{0}, G^{-1}(\theta)),$$

esto lleva a la región de confianza

$$RC_n^\dagger(\theta) = \{\theta : n(\hat{\theta}_n - \theta)^\top S^\top(\hat{\theta}_n)V^{-1}(\hat{\theta}_n)S(\hat{\theta}_n)(\hat{\theta}_n - \theta) \leq \chi_{1-\alpha}^2(k)\}.$$