

MGE-201: Test asintóticos para extremum estimation

Felipe Osorio

felipe.osorio@uv.cl

Test en el contexto de extremum estimation

Problema 1:

Considere la hipótesis simple $H_0 : \theta = \theta_0$, versus $H_1 : \theta \neq \theta_0$ con θ_0 fijado. En el contexto de extreme estimation, deseamos resolver

$$\max_{\theta \in \Theta} Q_n(\theta) \quad \text{sujeto a: } \theta = \theta_0.$$

Problema 2:

Deseamos probar hipótesis no lineales de la forma $H_0 : g(\theta) = \mathbf{0}$, donde $g : \mathbb{R}^p \rightarrow \mathbb{R}^q$, tal que $G(\theta) = \partial g(\theta) / \partial \theta^\top$ es una matriz $q \times p$ con rango q . En otras palabras, deseamos resolver el problema restringido:

$$\max_{\theta \in \Theta} Q_n(\theta) \quad \text{sujeto a: } g(\theta) = \mathbf{0}.$$

Test en el contexto de extremum estimation

Supuestos

B1: $Q_n(\theta)$ es dos veces diferenciable en θ .

B2: Sea $A_n(\theta) = \partial^2 Q_n(\theta) / \partial \theta \partial \theta^\top$ y asuma que

$$A_n(\theta) \xrightarrow{\text{a.s.}} A,$$

uniformemente.

B3: La matriz A es no singular.

B4: La secuencia $\{\sqrt{n}(\partial Q_n(\theta)/\partial \theta)\}$ converge en distribución a una normal estándar con vector de medias cero y matriz de covarianza B . Es decir,

$$\sqrt{n} \frac{\partial Q_n(\theta_0)}{\partial \theta} \xrightarrow{\text{D}} N_p(\mathbf{0}, B).$$

Test en el contexto de extremum estimation

Resultado 1 (test de Wald):

El **test de Wald** (asintóticamente) de tamaño α para probar la hipótesis $H_0 : \theta = \theta_0$, adopta la forma:

Rechazar H_0 si,

$$W_n \geq \chi^2_{1-\alpha}(p),$$

donde

$$W_n = n(\hat{\theta}_n - \theta_0)^\top \mathbf{A} \mathbf{B}^{-1} \mathbf{A} (\hat{\theta}_n - \theta_0),$$

con $\chi^2_{1-\alpha}(p)$ el valor cuantil $(1 - \alpha)$ de la distribución chi-cuadrado con p grados de libertad.

Test en el contexto de extremum estimation

Demostración:

Sabemos que

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1}),$$

luego

$$\mathbf{Z}_n = \sqrt{n}(\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})^{-1/2}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{I}),$$

como $(\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})^{-1/2} (\mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})^{-1/2} = \mathbf{A} \mathbf{B}^{-1} \mathbf{A}$, sigue que

$$\mathbf{Z}_n^\top \mathbf{Z}_n = n(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0)^\top \mathbf{A} \mathbf{B}^{-1} \mathbf{A} (\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \xrightarrow{D} \chi^2(p).$$

Test en el contexto de extremum estimation

Resultado 2 (test tipo-score):¹

El test tipo-score para probar $H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0$, es definido por la región crítica,

$$\{R_n \geq \chi^2_{1-\alpha}(p)\},$$

donde

$$R_n = n \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}},$$

y bajo H_0 es asintóticamente de tamaño α .

¹Boos (1992). The American Statistician **46**, 327-333.

Test en el contexto de extremum estimation

Demostración:

Por el supuesto B4, tenemos que

$$\sqrt{n} \mathbf{B}^{-1/2} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \xrightarrow{\text{D}} \mathcal{N}_p(\mathbf{0}, \mathbf{I}).$$

Luego

$$R_n = n \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1/2} \mathbf{B}^{-1/2} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \xrightarrow{\text{D}} \chi^2(p).$$

Test en el contexto de extremum estimation

Resultado 3 (test de forma bilineal):²

El estadístico de forma bilineal para probar la hipótesis nula $H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0$, asume la forma:

$$BF_n = n \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1} \mathbf{A} (\widehat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0),$$

y bajo H_0 , BF_n tiene distribución asintótica $\chi^2(p)$.

Observación:

Asumiendo que $\mathbf{B} = -\mathbf{A}$, sigue que

$$BF = n \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top (\widehat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0)$$

cuando $Q_n(\boldsymbol{\theta}) = \bar{\ell}_n(\boldsymbol{\theta})$, obtenemos la estadística gradiente dada por Terrell (2002).³

²Crudu y Osorio (2020). Economics Letters 187, 108885.

³Computing Sciences and Statistics 34, 206-215.

Test en el contexto de extremum estimation

Demostración:

Considere $\mathbf{B} = \mathbf{R}\mathbf{R}^\top$. De este modo,

$$\begin{aligned}\sqrt{n} \mathbf{R}^{-1} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} &\xrightarrow{\text{D}} \mathcal{N}_p(\mathbf{0}, \mathbf{I}), \\ \sqrt{n} \mathbf{R}^{-1} \mathbf{A}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) &\xrightarrow{\text{D}} \mathcal{N}_p(\mathbf{0}, \mathbf{I}).\end{aligned}$$

Basado en estas versiones estandarizadas, tenemos

$$BF_n = \left\{ \sqrt{n} \mathbf{R}^{-1} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right\}^\top \{ \sqrt{n} \mathbf{R}^{-1} \mathbf{A}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \},$$

y de este manera, sigue que $BF_n \xrightarrow{\text{D}} \chi^2(p)$.

Test en el contexto de extremum estimation

Ejemplo (Una función objetivo cuadrática):

Sea

$$Q_n(\boldsymbol{\theta}) = -\frac{1}{2} \mathbf{f}_n^\top(\boldsymbol{\theta}) \mathbf{W}^{-1} \mathbf{f}_n(\boldsymbol{\theta}),$$

donde $\mathbf{f}_n(\boldsymbol{\theta})$ es un conjunto de condiciones de momentos y \mathbf{W} es una matriz definida positiva con órdenes apropiados, entonces

$$\frac{\partial Q_n(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = -\mathbf{F}_n^\top(\boldsymbol{\theta}) \mathbf{W}^{-1} \mathbf{f}_n(\boldsymbol{\theta}),$$

con $\mathbf{F}_n(\boldsymbol{\theta}) = \partial \mathbf{f}_n(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}^\top$, y

$$\frac{\partial^2 Q_n(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} = -\left[\frac{\partial \mathbf{F}_n^\top(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right] [\mathbf{W}^{-1} \mathbf{f}_n(\boldsymbol{\theta})] - \mathbf{F}_n^\top(\boldsymbol{\theta}) \mathbf{W}^{-1} \mathbf{F}_n(\boldsymbol{\theta}),$$

donde $[\cdot][\cdot]$ denota multiplicación entre arreglos. Si $\sqrt{n} \mathbf{f}_n(\boldsymbol{\theta}_0) \xrightarrow{D} \mathcal{N}(\mathbf{0}, \mathbf{W})$, entonces:

$$\mathbf{B} = \mathbf{F}^\top \mathbf{W}^{-1} \mathbf{F}, \quad \mathbf{A} = -\mathbf{F}^\top \mathbf{W}^{-1} \mathbf{F}.$$

De ahí que, $\mathbf{B} = -\mathbf{A}$ se satisface.

Test en el contexto de extremum estimation

Propiedad 1:

Tenemos que

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \stackrel{a}{=} \mathbf{A}^{-1} \sqrt{n} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}}.$$

De ahí que, bajo $H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0$ podemos apreciar

$$\begin{aligned} BF_n &= \sqrt{n} \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1} \mathbf{A} \{ \sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0) \} \\ &\stackrel{a}{=} \sqrt{n} \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1} \mathbf{A} \mathbf{A}^{-1} \sqrt{n} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \\ &\stackrel{a}{=} n \left(\frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{B}^{-1} \frac{\partial Q_n(\boldsymbol{\theta}_0)}{\partial \boldsymbol{\theta}} \equiv R_n \end{aligned}$$

donde R_n corresponde al **estadístico tipo-score** para probar $H_0 : \boldsymbol{\theta} = \boldsymbol{\theta}_0$ en extreme estimation (ver Rotnitzky and Jewell, 1990⁴ y Boos, 1992).

⁴ Biometrika 77, 485-497.

Test en el contexto de extremum estimation

Sea $\{\tilde{\theta}_n\}$ una secuencia de estimadores que son solución del problema

$$\max_{\theta \in \Theta} Q_n(\theta) \quad \text{sujeto a: } g(\theta) = \mathbf{0}.$$

El estimador restringido $\tilde{\theta}_n$ satisface las condiciones de primer-orden:

$$\frac{\partial Q_n(\tilde{\theta}_n)}{\partial \theta} - G(\tilde{\theta}_n)^\top \tilde{\lambda}_n = \mathbf{0}$$

$$g(\tilde{\theta}_n) = \mathbf{0},$$

donde $\tilde{\lambda}_n$ es una secuencia de multiplicadores de Lagrange.

Test en el contexto de extremum estimation

Objetivo:

Deseamos obtener estadísticos de prueba para [test de hipótesis no lineales](#), de la forma:

$$H_0 : \mathbf{g}(\boldsymbol{\theta}_0) = \mathbf{0} \quad \text{against} \quad H_1 : \mathbf{g}(\boldsymbol{\theta}_0) \neq \mathbf{0}.$$

Sabemos que, bajo H_0 ,

$$\sqrt{n} \mathbf{g}(\widehat{\boldsymbol{\theta}}_n) \xrightarrow{\text{D}} \mathcal{N}_q(\mathbf{0}, \boldsymbol{\Omega}), \tag{A.1}$$

donde $\boldsymbol{\Omega} = \mathbf{G} \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1} \mathbf{G}^\top$, y

$$\mathbf{G} = \frac{\partial \mathbf{g}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^\top} \Big|_{\boldsymbol{\theta}=\boldsymbol{\theta}_0}.$$

Test en el contexto de extremum estimation

Notando que

$$\sqrt{n} \mathbf{g}(\hat{\boldsymbol{\theta}}_n) \stackrel{a}{=} \mathbf{G}(-\mathbf{A})^{-1} \sqrt{n} \frac{\partial Q_n(\tilde{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta}}$$

y desde la condición de primer orden

$$\sqrt{n} \frac{\partial Q_n(\tilde{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta}} \stackrel{a}{=} \mathbf{G}^\top(\tilde{\boldsymbol{\theta}}_n) \sqrt{n} \tilde{\boldsymbol{\lambda}}_n.$$

Obtenemos que

$$\sqrt{n} \tilde{\boldsymbol{\lambda}}_n \stackrel{a}{=} [\mathbf{G}(-\mathbf{A})^{-1} \mathbf{G}^\top]^{-1} \sqrt{n} \mathbf{g}(\hat{\boldsymbol{\theta}}_n). \quad (\text{A.2})$$

Entonces, usando la distribución asintótica dada en (A.1), hallamos

$$\sqrt{n} \tilde{\boldsymbol{\lambda}}_n \xrightarrow{D} \mathcal{N}_q(\mathbf{0}, \mathbf{S}^{-1} \boldsymbol{\Omega} \mathbf{S}^{-1}),$$

donde $\mathbf{S} = \mathbf{G}(-\mathbf{A})^{-1} \mathbf{G}^\top$.

Test en el contexto de extremum estimation

Resultado 4 (test de Wald):

El [test de Wald](#) para probar $H_0 : \mathbf{g}(\theta) = \mathbf{0}$, es definido por la región crítica,

$$\{W_n \geq \chi^2_{1-\alpha}(q)\},$$

donde

$$W_n = n\mathbf{g}^\top(\hat{\theta}_n)[\mathbf{G}(\hat{\theta}_n)\mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}\mathbf{G}^\top(\hat{\theta}_n)]^{-1}\mathbf{g}(\hat{\theta}_n),$$

y bajo H_0 es asintóticamente de tamaño α .

Demostración:

Basta notar que por Ecuación [\(A.1\)](#),

$$W_n = \{\sqrt{n}\hat{\Omega}^{-1/2}\mathbf{g}^\top(\hat{\theta}_n)\}^\top \sqrt{n}\hat{\Omega}^{-1/2}\mathbf{g}^\top(\hat{\theta}_n) \xrightarrow{D} \chi^2(q).$$

Test en el contexto de extremum estimation

Resultado 5 (test tipo-score o de multiplicadores de Lagrange):

El estadístico tipo-score o de multiplicadores de Lagrange para probar la hipótesis $H_0 : g(\theta_0) = 0$, es dado por

$$R_n = n \tilde{\lambda}_n^\top \tilde{S} \tilde{\Omega}^{-1} \tilde{S} \tilde{\lambda}_n,$$

y bajo H_0 tiene distribución asintótica chi-cuadrado con q grados de libertad.

Demostración:

Por la Ecuación (A.2), tenemos

$$R_n = \{\sqrt{n} (\tilde{S}^{-1} \tilde{\Omega} \tilde{S}^{-1})^{-1/2} \tilde{\lambda}_n\}^\top \sqrt{n} (\tilde{S}^{-1} \tilde{\Omega} \tilde{S}^{-1})^{-1/2} \tilde{\lambda}_n \xrightarrow{D} \chi^2(q).$$

Test en el contexto de extremum estimation

Resultado 6 (test de forma bilineal)⁵

El estadístico de forma bilineal para probar la hipótesis nula $H_0 : \mathbf{g}(\boldsymbol{\theta}_0) = \mathbf{0}$ es dada por

$$BF_{n,1} = n \tilde{\lambda}_n^\top \mathbf{S} \boldsymbol{\Omega}^{-1} \mathbf{g}(\hat{\boldsymbol{\theta}}_n),$$

y bajo H_0 , BF_1 tiene una distribución chi-cuadrado con q grados de libertad.

Demostración:

Sea $\boldsymbol{\Omega} = \mathbf{R}\mathbf{R}^\top$ donde \mathbf{R} es una matriz no singular $q \times q$. De este modo,

$$\sqrt{n} \mathbf{R}^{-1} \mathbf{S} \tilde{\lambda}_n \xrightarrow{\text{D}} \mathcal{N}_q(\mathbf{0}, \mathbf{I}), \quad \sqrt{n} \mathbf{R}^{-1} \mathbf{g}(\hat{\boldsymbol{\theta}}_n) \xrightarrow{\text{D}} \mathcal{N}_q(\mathbf{0}, \mathbf{I}),$$

lo que permite establecer el resultado.

⁵Crudu y Osorio (2020). Economics Letters 187, 108885.

Test en el contexto de extremum estimation

Resultado 7

El **estadístico de forma bilineal** tiene las siguientes formulaciones alternativas. Sea $\mathbf{G}^+ = \mathbf{G}^\top (\mathbf{G}\mathbf{G}^\top)^{-1}$ la inversa Moore-Penrose de \mathbf{G} . Entonces,

$$BF_{n,2} = n \left(\frac{\partial Q_n(\tilde{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{G}^+ \mathbf{S} \boldsymbol{\Omega}^{-1} \mathbf{g}(\hat{\boldsymbol{\theta}}_n),$$

$$BF_{n,3} = n \left(\frac{\partial Q_n(\tilde{\boldsymbol{\theta}}_n)}{\partial \boldsymbol{\theta}} \right)^\top \mathbf{G}^+ \mathbf{S} \boldsymbol{\Omega}^{-1} \mathbf{G}(\hat{\boldsymbol{\theta}}_n - \tilde{\boldsymbol{\theta}}_n),$$

y bajo H_0 , $BF_k \xrightarrow{D} \chi^2(q)$, $k = 2, 3$.

Test en el contexto de extremum estimation

Observación:

Defina $P = G^+G$ y asuma que $B = -A$, lo que lleva a $S = \Omega$. Obtenemos las siguientes especificaciones

$$BF_{n,4} = n \tilde{\lambda}_n^\top g(\hat{\theta}_n),$$

$$BF_{n,5} = n \left(\frac{\partial Q_n(\tilde{\theta}_n)}{\partial \theta} \right)^\top G^+ g(\hat{\theta}_n),$$

$$BF_{n,6} = n \left(\frac{\partial Q_n(\tilde{\theta}_n)}{\partial \theta} \right)^\top P(\hat{\theta}_n - \tilde{\theta}_n),$$

$$BF_{n,7} = n \left(\frac{\partial Q_n(\tilde{\theta}_n)}{\partial \theta} \right)^\top (\hat{\theta}_n - \tilde{\theta}_n),$$

y $BF_k \xrightarrow{D} \chi^2(q)$, $k = 4, 5, 6, 7$, bajo $H_0 : g(\theta_0) = 0$.

Test en el contexto de extremum estimation

Observación:

Cuando $Q_n(\boldsymbol{\theta}) = \bar{\ell}_n(\boldsymbol{\theta})$ es la función de log-verosimilitud obtenemos que la estadística BF_n es dada por

$$BF_n = \tilde{\lambda}^\top \mathbf{g}(\hat{\boldsymbol{\theta}}) = \mathbf{U}_n^\top (\tilde{\boldsymbol{\theta}}) \mathbf{G}^+ \mathbf{g}(\hat{\boldsymbol{\theta}}),$$

donde $\mathbf{U}_n(\tilde{\boldsymbol{\theta}}) = \partial \bar{\ell}_n(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}$ es la función score.

Observación:

Sea

$$D_n = n(Q_n(\tilde{\boldsymbol{\theta}}) - Q_n(\hat{\boldsymbol{\theta}})),$$

la estadística de distancia métrica. Debemos resaltar que para el modelo lineal $\mathbf{Y} = \mathbf{X}\boldsymbol{\theta} + \epsilon$, D_n y BF_n son iguales. Más aún, el estadístico BF_n asume la forma

$$BF_n = (\mathbf{Y} - \mathbf{X}\tilde{\boldsymbol{\theta}}_n)^\top \mathbf{X} \mathbf{B}^{-1} \mathbf{X}^\top \mathbf{X} (\hat{\boldsymbol{\theta}}_n - \tilde{\boldsymbol{\theta}}_n).$$

Test en el contexto de extremum estimation

Propiedad 2:

El estadístico $BF_{n,1}$ y el estadístico de multiplicadores de Lagrange son asintóticamente equivalentes y bajo $H_0 : \mathbf{g}(\boldsymbol{\theta}) = \mathbf{0}$ su distribución asintótica común es $\chi^2(q)$.

Demostración:

Desde (A.2), tenemos que

$$\sqrt{n} \mathbf{g}(\hat{\boldsymbol{\theta}}_n) \stackrel{\text{a}}{=} \mathbf{G}(-\mathbf{A})^{-1} \mathbf{G}^\top \sqrt{n} \tilde{\boldsymbol{\lambda}}_n = \mathbf{S} \sqrt{n} \tilde{\boldsymbol{\lambda}}_n,$$

y esto lleva a,

$$\begin{aligned} BF_n &= \sqrt{n} \tilde{\boldsymbol{\lambda}}_n \mathbf{S} \boldsymbol{\Omega}^{-1} \sqrt{n} \mathbf{g}(\hat{\boldsymbol{\theta}}_n) \\ &\stackrel{\text{a}}{=} \sqrt{n} \tilde{\boldsymbol{\lambda}}_n \mathbf{S} \boldsymbol{\Omega}^{-1} \mathbf{S} \sqrt{n} \tilde{\boldsymbol{\lambda}}_n \equiv R_n. \end{aligned}$$

Experimento numérico: Estudio de simulación Monte Carlo

Basado en el estudio de simulación introducido por Gregory y Veall (1985)⁶.

Se generó $M = 5\,000$ conjuntos de datos de tamaños $n = 20, 50, 100, 500$ considerando la siguiente especificación de modelo:

$$\mathbf{Y} = \mathbf{1}_n \theta_1 + \mathbf{x}_2 \theta_2 + \exp(\mathbf{x}_3 \theta_3) + \epsilon,$$

donde $\mathbf{x}_j \sim \mathcal{N}_n(\mathbf{0}, 0.16\mathbf{I})$, $j = 2, 3$ y $\epsilon \sim \mathcal{N}_n(\mathbf{0}, 0.16\mathbf{I})$.

Deseamos probar dos hipótesis nulas equivalentes

$$H_0^A : \theta_2 - \frac{1}{\theta_3} = 0, \quad H_0^B : \theta_2 \theta_3 - 1 = 0.$$

usando las estadísticas de forma bilineal (*BF*), Wald (*W*), multiplicadores de Langrange (*R*) y distancia métrica (*D*).

Corrimos nuestras simulaciones en un servidor HP Proliant DL360, procesador Intel Xeon E5-2630 con 192 GB de RAM (tiempo total de simulación: 23 hrs, 40 min, 3 seg).⁷

⁶Econometrica 53, 1465-1468.

⁷código R disponible en: https://github.com/faosorios/BF_EE

Resultados: Tamaños empíricos para un test del 5%⁸

Escenario	$(\theta_1, \theta_2, \theta_3)$	n	W^A	W^B	BF^A	BF^B	R	D
I	(1,10,0.1)	20	0.420	0.176	0.067	0.064	0.084	0.087
		50	0.282	0.106	0.065	0.059	0.068	0.074
		100	0.197	0.077	0.059	0.059	0.061	0.061
		500	0.104	0.052	0.048	0.048	0.049	0.049
II	(1,5,0.2)	20	0.277	0.178	0.068	0.065	0.083	0.086
		50	0.171	0.108	0.058	0.057	0.067	0.068
		100	0.127	0.078	0.058	0.058	0.061	0.062
		500	0.070	0.052	0.047	0.047	0.048	0.048
III	(1,2,0.5)	20	0.145	0.175	0.066	0.067	0.082	0.082
		50	0.096	0.113	0.062	0.057	0.070	0.075
		100	0.078	0.082	0.056	0.056	0.062	0.062
		500	0.049	0.055	0.045	0.045	0.050	0.050
IV	(1,1,1)	20	0.140	0.170	0.084	0.070	0.086	0.101
		50	0.095	0.108	0.062	0.062	0.070	0.070
		100	0.074	0.080	0.066	0.066	0.067	0.067
		500	0.055	0.055	0.056	0.056	0.061	0.061

⁸Los superíndices A y B refieren al hecho de que W y BF son calculados usando las hipótesis nulas H_0^A y H_0^B

Estudio de simulación Monte Carlo: Potencia del test BF

Se condujo un estudio de simulación adicional basado en $M = 1\,000$ conjuntos de datos con tamaños muestrales $n = 20, 50, 100$, calculando la **potencia empírica** bajo las **hipótesis alternativas**:

$$H_1^A : \beta_2 - \delta/\beta_3 = 0,$$

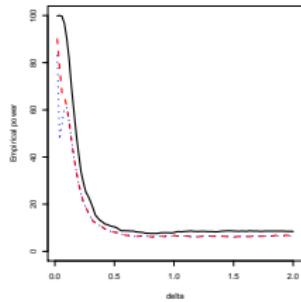
y

$$H_1^B : \beta_2\beta_3 - \delta = 0,$$

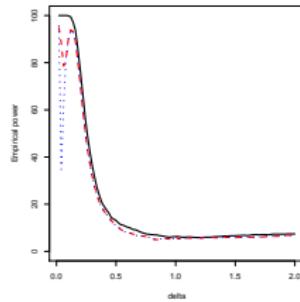
considerando $\delta \in [0, 2]$ para cada uno de los escenarios.⁹

⁹Sólo las potencias empíricas de R , BF^A y BF^B son reportadas.

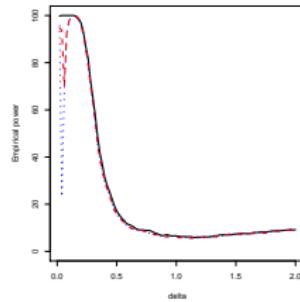
Resultados: Potencias empíricas para R , BF^A y BF^B , escenarios I y II



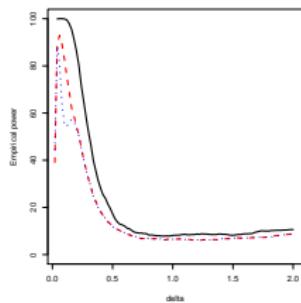
(a) $n = 20$



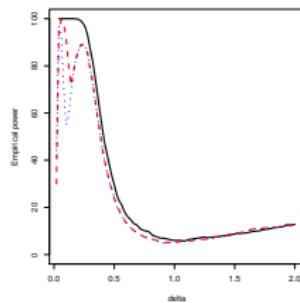
(b) $n = 50$



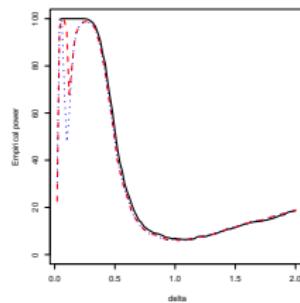
(c) $n = 100$



(d) $n = 20$

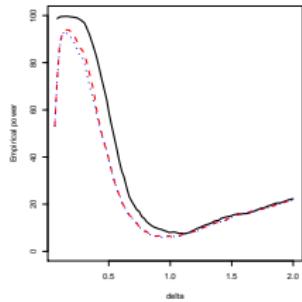


(e) $n = 50$

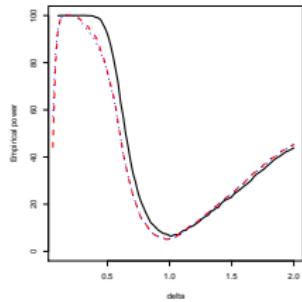


(f) $n = 100$

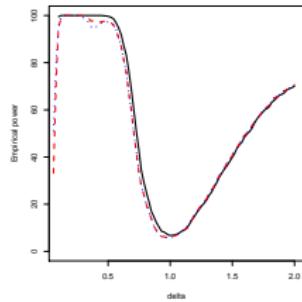
Resultados: Potencias empíricas para R , BF^A y BF^B , escenarios III y IV



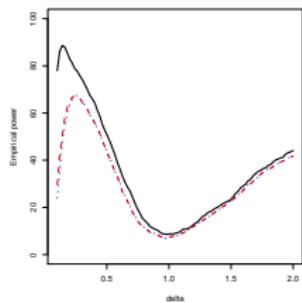
(a) $n = 20$



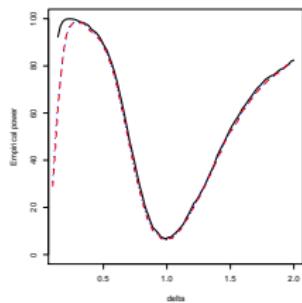
(b) $n = 50$



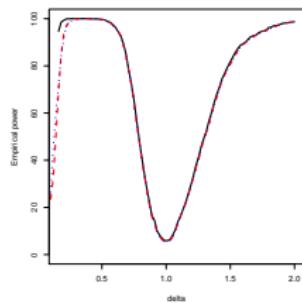
(c) $n = 100$



(d) $n = 20$



(e) $n = 50$



(f) $n = 100$

Probando la igualdad de razones de Sharpe

Considere $\mathbf{Y} = (Y_1, \dots, Y_p)^\top$ un vector aleatorio p -dimensional con vector de medias $\boldsymbol{\mu} \in \mathbb{R}^p$ y matriz de covarianza $\boldsymbol{\Sigma}$. Para evaluar una estrategia de inversión, Sharpe (1966)¹⁰ propuso la razón:

$$\lambda_j = \frac{\mu_j}{\sqrt{\sigma_{jj}}}, \quad j = 1, \dots, p.$$

Sea $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_p)^\top$ el vector de razones de Sharpe para un portfolio con p inversiones. Deseamos probar la hipótesis:¹¹

$$H_0 : \lambda_1 = \lambda_2 = \dots = \lambda_p \quad (= \boldsymbol{\lambda})$$

¹⁰Journal of Business **39**, 119-138.

¹¹Trabajo en colaboración con Manuel Galea (PUC, Chile).

Probando la igualdad de razones de Sharpe

Considere una muestra aleatoria $\mathbf{Y}_1, \dots, \mathbf{Y}_n$ from $T_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}, \eta)$ con densidad

$$f(\mathbf{y}) = \left(\frac{c(\eta)}{\pi} \right)^{p/2} \frac{\Gamma(\frac{1+\eta p}{2\eta})}{\Gamma(\frac{1}{2\eta})} (1 + c(\eta)D^2)^{-\frac{1}{2}(1+\eta p)}, \quad 0 < \eta < 1/2,$$

donde $c(\eta) = \eta/(1 - 2\eta)$ y $D^2 = (\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{y} - \boldsymbol{\mu})$ denota la distancia de Mahalanobis.

Note que, **bajo H_0** tenemos $\mu_j = \lambda\sqrt{\sigma_{jj}}$, $j = 1, \dots, p$. Esto es, podemos escribir:

$$\mathbf{Y}_i | \omega_i \stackrel{\text{ind}}{\sim} N_p(\lambda\boldsymbol{\sigma}^{1/2}, \boldsymbol{\Sigma}), \quad \omega_i \stackrel{\text{ind}}{\sim} \text{Gamma}\left(\frac{1}{2\eta}, \frac{1}{2c(\eta)}\right),$$

para $i = 1, \dots, n$. Además $\boldsymbol{\Sigma} = \mathbf{D}^{-1/2} \boldsymbol{\Omega} \mathbf{D}^{-1/2}$ con $\mathbf{D} = \text{diag}(\boldsymbol{\sigma})$.

Probando la igualdad de razones de Sharpe

- ▶ Usamos un algoritmo ECM (Meng and Rubin, 1993)¹² para obtener estimadores ML restringidos de $\theta = (\lambda, \sigma^\top, \rho^\top, \eta)^\top$, con $\Gamma = \Gamma(\rho)$.
- ▶ Para eficiencia computacional, la siguiente reparametrización fue considerada

$$\begin{aligned}\phi_j &= \log \sigma_{jj}, & j &= 1, \dots, p, \\ \Gamma^{-1} &= \Delta^\top \Delta,\end{aligned}$$

con Δ matriz triangular inferior.

- ▶ De este modo, podemos escribir:

$$Q(\theta | \theta^{(k)}) = Q_1(\tau | \theta^{(k)}) + Q_2(\eta | \theta^{(k)}),$$

donde $\tau = (\lambda, \phi^\top, \rho^\top)^\top$.

¹²Biometrika 80, 267-278.

Probando la igualdad de razones de Sharpe

- **Paso E:** Para una estimación inicial $\boldsymbol{\theta} = \boldsymbol{\theta}^{(k)}$, calcular:

$$Q_1(\boldsymbol{\tau} | \boldsymbol{\theta}^{(k)}) = -\frac{n}{2} \operatorname{tr} \boldsymbol{\Phi} + n \log |\boldsymbol{\Delta}|$$
$$-\frac{1}{2} \sum_{i=1}^n \omega_i^{(k)} \{ \boldsymbol{\Delta}(e^{-\boldsymbol{\Phi}/2} \mathbf{y}_i - \lambda \mathbf{1}) \}^\top \boldsymbol{\Delta}(e^{-\boldsymbol{\Phi}/2} \mathbf{y}_i - \lambda \mathbf{1})$$

y

$$Q_2(\eta | \boldsymbol{\theta}^{(k)}) = n \left\{ \frac{1}{2\eta} \log \left(\frac{1}{2c(\eta)} \right) - \log \Gamma \left(\frac{1}{2\eta} \right) + \frac{1}{2c(\eta)} \left[\psi \left(\frac{1/\eta^{(k)} + p}{2} \right) \right. \right.$$
$$\left. \left. - \log \left(\frac{1/\eta^{(k)} + p}{2} \right) + \frac{1}{n} \sum_{i=1}^n (\log \omega_i^{(k)} - \omega_i^{(k)}) \right] \right\},$$

donde

$$\omega_i^{(k)} = \frac{1/\eta^{(k)} + p}{1/c(\eta^{(k)}) + D_i^2(\lambda^{(k)}, \boldsymbol{\phi}^{(k)}, \boldsymbol{\rho}^{(k)})},$$

con¹³

$$D_i^2(\lambda, \boldsymbol{\phi}, \boldsymbol{\rho}) = \|\mathbf{z}_i\|^2, \quad \mathbf{z}_i = \boldsymbol{\Delta}(e^{-\boldsymbol{\Phi}/2} \mathbf{y}_i - \lambda \mathbf{1}), \quad i = 1, \dots, n.$$

¹³Note que \mathbf{z}_i es solución de $\mathbf{L}\mathbf{z}_i = e^{-\boldsymbol{\Phi}/2} \mathbf{y}_i - \lambda \mathbf{1}$, con $\boldsymbol{\Gamma} = \mathbf{L}\mathbf{L}^\top$.

Probando la igualdad de razones de Sharpe

- **Paso CM-1:** Para $\phi = \phi^{(k)}$ y $\rho = \rho^{(k)}$, actualizar:¹⁴

$$\lambda^{(k+1)} = \frac{1}{\mathbf{1}^\top \boldsymbol{\Delta} \mathbf{1}} \mathbf{1}^\top \boldsymbol{\Delta} e^{-\Phi/2} \boldsymbol{\mu}^{(k+1)}, \quad \boldsymbol{\mu}^{(k+1)} = \frac{1}{\sum_{i=1}^n \omega_i^{(k)}} \sum_{i=1}^n \omega_i^{(k)} \mathbf{y}_i.$$

- **Paso CM-2:** Calcular:

$$\boldsymbol{\Sigma}^{(k+1)} = \frac{1}{n} \sum_{i=1}^n \omega_i^{(k)} (\mathbf{y}_i - \boldsymbol{\mu}^{(k+1)}) (\mathbf{y}_i - \boldsymbol{\mu}^{(k+1)})^\top = \frac{1}{n} \sum_{i=1}^n \omega_i^{(k)} \mathbf{z}_i \mathbf{z}_i^\top.$$

Para $\phi = \phi^{(k)}$ y $\lambda = \lambda^{(k+1)}$, sea $\mathbf{D}^{-1/2} \boldsymbol{\Sigma}^{(k+1)} \mathbf{D}^{-1/2} = \boldsymbol{\Gamma}^{(k+1)}$. Usando la condición de primer orden, tenemos

$$\boldsymbol{\Delta}^{-1} - \boldsymbol{\Gamma} \boldsymbol{\Delta}^\top = \mathbf{0},$$

esto es, $\boldsymbol{\Gamma}^{(k+1)}$ es la solución de la ecuación:

$$\boldsymbol{\Gamma}^{-1} - \boldsymbol{\Delta}^\top \boldsymbol{\Delta} = \mathbf{0}.$$

¹⁴Note que, $\mathbf{r}^{(k+1)} = e^{-\Phi/2} \boldsymbol{\mu}^{(k+1)}$ es el vector de razones de Sharpe estimadas.

Probando la igualdad de razones de Sharpe

- ▶ Paso CM-3: Para actualizar $\phi^{(k+1)}$ consideramos el [método secante multivariado](#) (Nash, 1990), usando BFGS maximizamos

$$f(\phi) = -Q_1(\lambda^{(k+1)}, \phi, \rho^{(k+1)} | \theta^{(k)}),$$

donde

$$f(\phi) = \frac{n}{2} \operatorname{tr} \Phi - n \log |\Delta| + \frac{1}{2} \sum_{i=1}^n \omega_i^{(k)} \|z_i\|^2$$

$$\dot{f}(\phi) = \mathbf{1} + \frac{1}{n} \sum_{i=1}^n \omega_i^{(k)} \operatorname{diag}(\mathbf{y}_i z_i^\top \Delta^\top \Delta e^{-\Phi/2})$$

- ▶ Paso CM-4: actualizar el parámetro de forma maximizando $Q_2(\eta | \theta^{(k)})$ con relación a η , esto es,

$$\eta^{(k+1)} = \arg \max_{\eta} Q_2(\eta | \theta^{(k)}),$$

usando un [procedimiento de optimización unidimensional](#) (Brent, 1973).

Rentabilidades de administradoras de fondos de pensiones (AFP) chilenas

Aplicación:

El sistema de pensiones Chileno (o sistema de capitalización individual) ha estado en efecto desde 1980.

AFPs son compañías privadas que invierten los fondos de los cotizantes en un portfolio de títulos de inversión.

Existe 5 tipos de fondos (A, B, C, D, E), diferenciados por la proporción que es invertida en instrumentos de renta variable.

Fondo A representa un portfolio de alto riesgo. El riesgo disminuye progresivamente para los fondos B, C, D y E.

Datos:

Retornos mensuales de AFPs: Cuprum, Habitat, PlanVital y ProVida entre Agosto 2005 y Diciembre 2013.

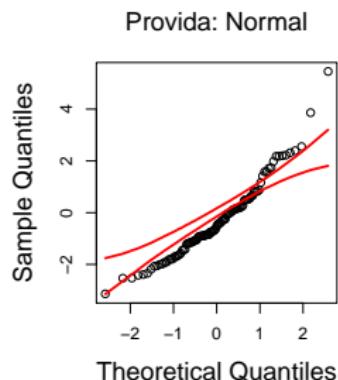
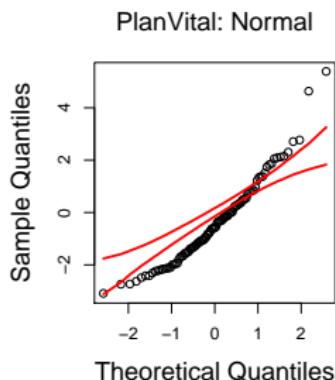
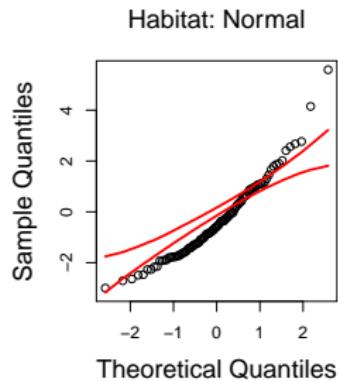
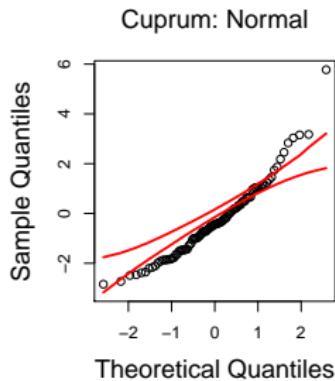
Datos fueron obtenidos desde el sitio web de la superintendencia de pensiones (www.spensiones.cl)

Conjunto de datos con 101 observaciones y 4 variables.

Obs. 28, 30, 35, 38, 39, 42, 66, 73 y 75 son identificadas como outliers.

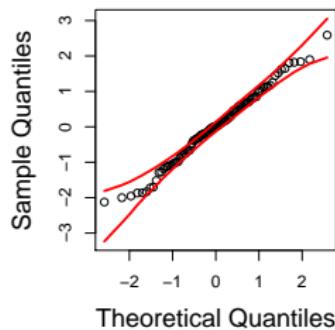
QQ-plot de distancias transformadas resalta la presencia de colas más pesadas que la normal.

QQ-plots bajo el modelo normal: datos de AFP

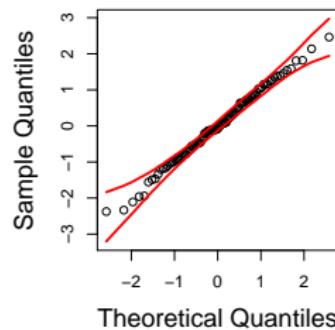


QQ-plots bajo el modelo t multivariado: datos de AFP

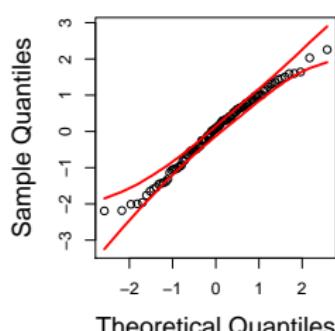
Cuprum: t-distribution



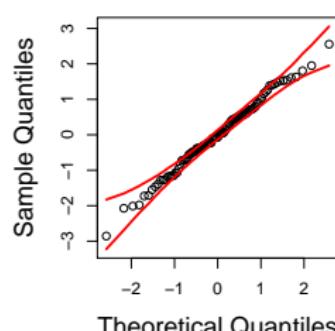
Habitat: t-distribution



PlanVital: t-distribution



Provida: t-distribution



Estimaciones de las razones de Sharpe: datos de AFP

Estimaciones de las razones de Sharpe $\widehat{\lambda}_i = \widehat{\mu}_i / \widehat{\sigma}_{ii}^{1/2}$, $i = 1, \dots, p$, asumiendo modelos normal y t multivariado.

- Modelo normal:

AFP	Fondo				
	A	B	C	D	E
Cuprum	0.083	0.106	0.168	0.253	0.309
Habitat	0.095	0.122	0.181	0.291	0.355
Planvital	0.093	0.118	0.173	0.260	0.325
Provida	0.085	0.102	0.150	0.253	0.300

- Modelo t multivariado:

AFP	Fondo				
	A	B	C	D	E
Cuprum	0.164	0.182	0.233	0.324	0.387
Habitat	0.176	0.195	0.240	0.336	0.385
Planvital	0.177	0.194	0.231	0.302	0.334
Provida	0.187	0.199	0.244	0.347	0.367

Probando la igualdad de razones de Sharpe: AFP dataset

Probando $H_0 : \lambda_1 = \dots = \lambda_p$, asumiendo datos normales.

Test	Cuprum		Habitat	
	estadistica	valor- <i>p</i>	estadistica	valor- <i>p</i>
LRT	21.123	0.000	19.598	0.000
Wald	11.934	0.018	10.448	0.033
BF	23.332	0.000	21.499	0.000

Test	PlanVital		Provida	
	estadistica	valor- <i>p</i>	estadistica	valor- <i>p</i>
LRT	13.896	0.008	19.666	0.001
Wald	8.063	0.089	10.485	0.033
BF	14.852	0.005	21.581	0.000

Testing the equality of Sharpe ratios: AFP dataset

Probando $H_0 : \lambda_1 = \dots = \lambda_p$, asumiendo datos *t* multivariados.

Test	Cuprum		Habitat	
	estadistica	valor-p	estadistica	valor-p
LRT	51.578	0.000	54.781	0.000
Wald	13.427	0.009	13.071	0.011
BF	52.625	0.000	57.899	0.000

Test	PlanVital		Provida	
	estadistica	valor-p	estadistica	valor-p
LRT	37.799	0.000	48.544	0.000
Wald	8.614	0.072	14.312	0.006
BF	39.302	0.000	50.659	0.000

Otros tópicos de interés

- ▶ Los resultados vistos en esta sesión pueden ser usado para probar hipótesis en **modelos mal especificados**.
- ▶ Existe muy poca literatura sobre **test de hipótesis para funciones de inferencia (FI)**. (i.e., cuando una función objetivo $Q_n(\theta)$ no es disponible). Estamos trabajando en extender el **estadístico de forma bilineal** para FI¹⁵
- ▶ Test alternativos están basados en **bootstrap, rangos y permutaciones**.
- ▶ Test de hipótesis también son usados como ingredientes para realizar **análisis de diagnóstico** así como definir **residuos** en modelos más generales (usando, por ejemplo, el modelo de salto en la media).

¹⁵Trabajo conjunto con Cibele Russo (ICMC-USP, Brazil).

Referencias

-  Boos, D.D. (1992).
On generalized score tests.
The American Statistician 46, 327-333.
-  Crudu, F., Osorio, F. (2020).
Bilinear form test statistics for extremum estimation.
Economics Letters 187, 108885.
-  Dagenais, M.G., Dufour, J.M. (1991).
Invariance, nonlinear models, and asymptotic tests.
Econometrica 59, 1601-1615.
-  Gourieroux, C., and Monfort, A. (1995).
Statistics and Econometric Models: Testing, confidence regions, model selection, and asymptotic theory.
Cambridge University Press, Cambridge.
-  Gregory, A.W., Veall, M.R. (1985).
Formulating Wald tests of nonlinear restrictions.
Econometrica 53, 1465-1468.
-  Terrell, G.R. (2002).
The gradient statistic.
Computing Sciences and Statistics 34, 206-215.